# Contents



# 1 ASR 任务

ASR 任务表示为

$$W^* = argmax_w P(W/X) W^* = argmax_w P(X/W) P(W)$$

其中 $X$ 为语音提取后的特征向量，$W^*$ 为语句输出，$P(X/W)$ 使用声学模型建模，$P(W)$ 使用语言模型建模。

# 2 发音字典 Lexicon

考虑对单词/单字建模，英语与中文常用单词/单字的数目十分庞大，并且训练集的规模限制导致极易出现 OOV(Out Of Vocabulary) 问题。

考虑对音素建模，英语中音素总量约 50 个，这极大的减少了模型数量。

同时，每个音素的声学特征在随发音过程而变化，通常将每个音素划分为 3 状态，即开始，稳定与结束状态。

问题在于模型如何确定某个单词由哪些音素构成？事实是模型无法确定，这种映射需要引入人工发音字典。

# 3 Acoustic Model 声学模型

输入语音，输出句子，只考虑语音与文字的对应关系，不考虑文字间的概率，即语义语法等关系。

## 3.1 GMM+HMM (Monophone)

使用 GMM(高斯混合模型) 与 HMM(隐马尔可夫模型) 构成单音素模型，GMM 对每个状态建模，HMM 对每个音素建模。

1. 将输入语音切分提取MFCC特征帧
2. GMM模型预测特征帧属于某音素某状态的概率
3. 使用Viterbi算法计算每个单词的HMM生成该序列的概率
4. 选择最大概率的单词作为输出

对 N 个单词三状态的语料库，需要 $N$ 个 HMM 与 $N*3$ 个 GMM，GMM 分量则需要人工设定。

## 3.2 GMM+HMM (Triphone)

Triphone 三音素预测考虑了相邻音素对该音素发音的影响，$N$ 个音素的集合理论上可构成 $N^3$ 个 triphone，假设每个 triphone 有三个状态，直接建模需要 $N^3*3$ 个 GMM，随着状态划分的增长，音素规模的增大，GMM 模型的数量极其庞大。

考虑引入状态共享，即不同音素的状态可以共享同一个 GMM 模型，这种划分通常使用决策树完成。

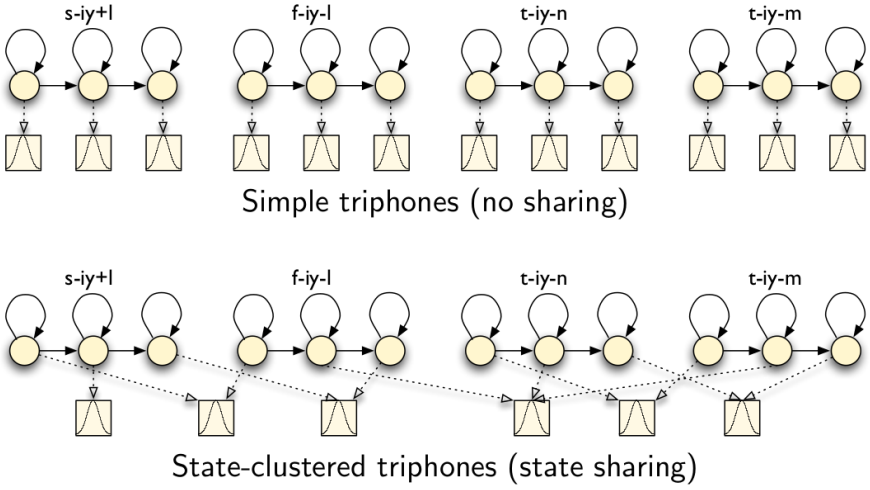

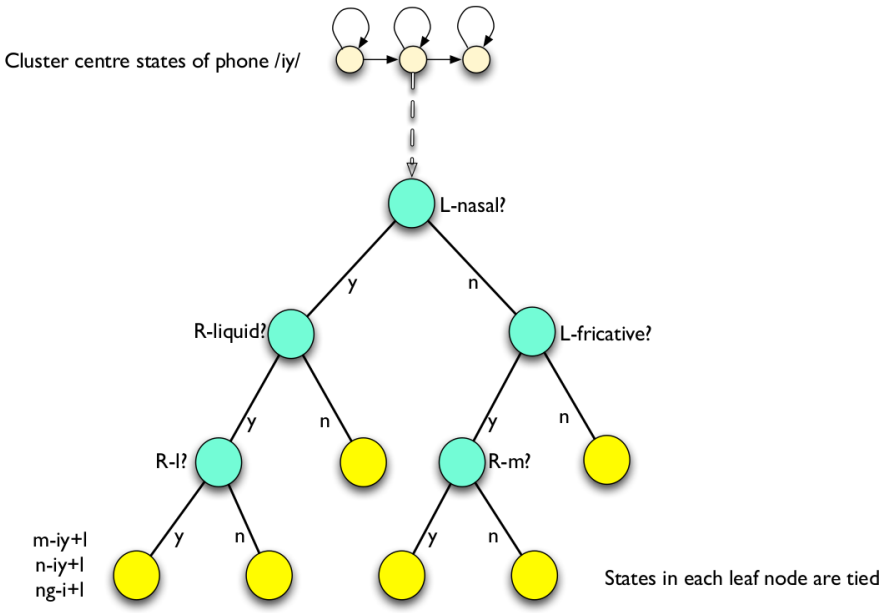


### 3.3 NN+HMM (Monophone)

使用神经网络代替 GMM 输出观测概率。

### 3.4 TDNN+HMM (Triphone)

TDNN 引入时序依赖，与 Triphone 相似，可以建模相邻音素 $V_{t-1}, V_{t+1}$ 之间的影响，同时得益于神经网络权值共享的概念，可以对更长时间依赖的音素 $V_{t-3}, V_{t+3}$ 进行建模。

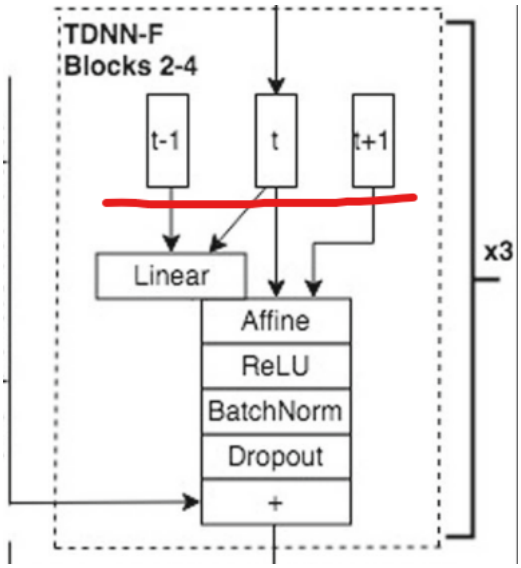


### 3.5 CNN+TDNN+HMM(Triphone)

使用 CNN 权值共享的特征，针对每个输入特征对 $V_{t-1}, V_t, V_{t+1}$ 进行卷积建模。

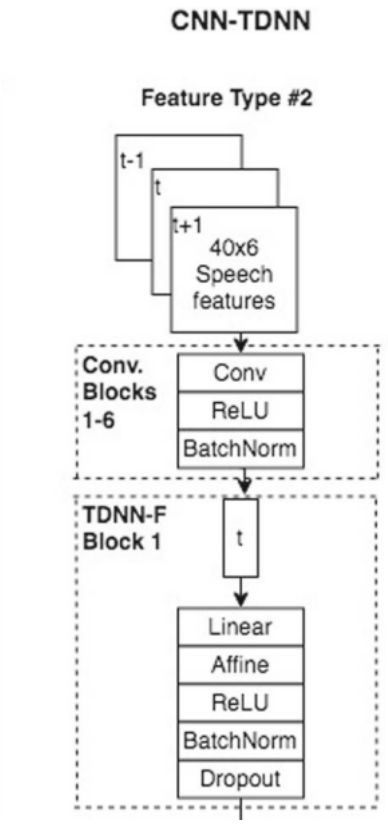


### 3.6 NN+CTC(Triphone)

这部分模型使用 RNN 替代 TDNN/CNN 等进行更强的时序建模，拓展时序依赖关系，同时将 HMM 替换为了 CTC 模型，来解决变长序列的建模问题。

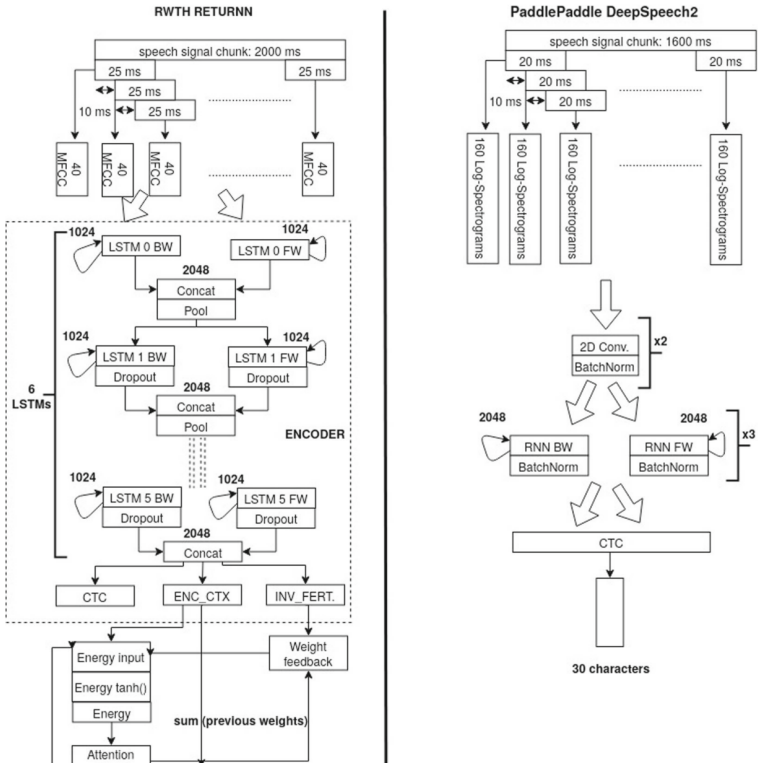


## 3.7 CNN

使用纯 CNN 架构, 参数量与计算量均较大。

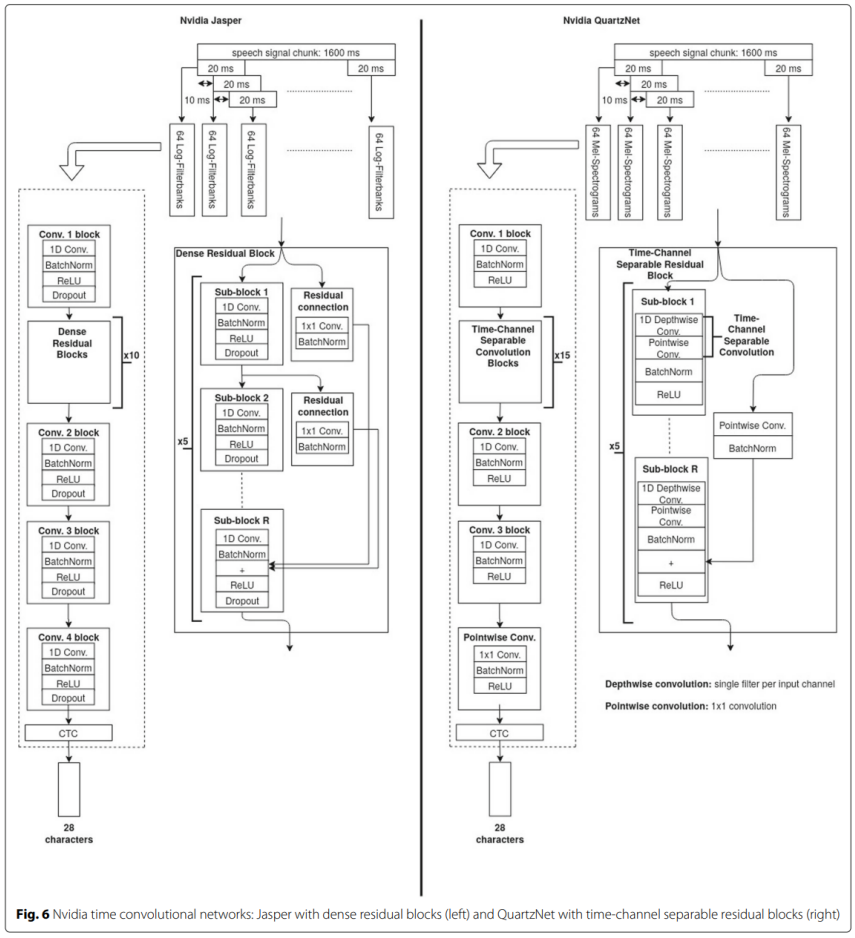


**Fig. 6** Nvidia time convolutional networks: Jasper with dense residual blocks (left) and QuartzNet with time-channel separable residual blocks (right)

## 3.8 RNN / RNN

这部分模型往往使用 Encoder/Decoder 结构，RNN 替代 TDNN/CNN 等拓展时序依赖关系进行更强的时序建模作为 Encoder，Decoder 同样使用 RNN。

输入仍然是 MFCC 特征提取后的特征向量。

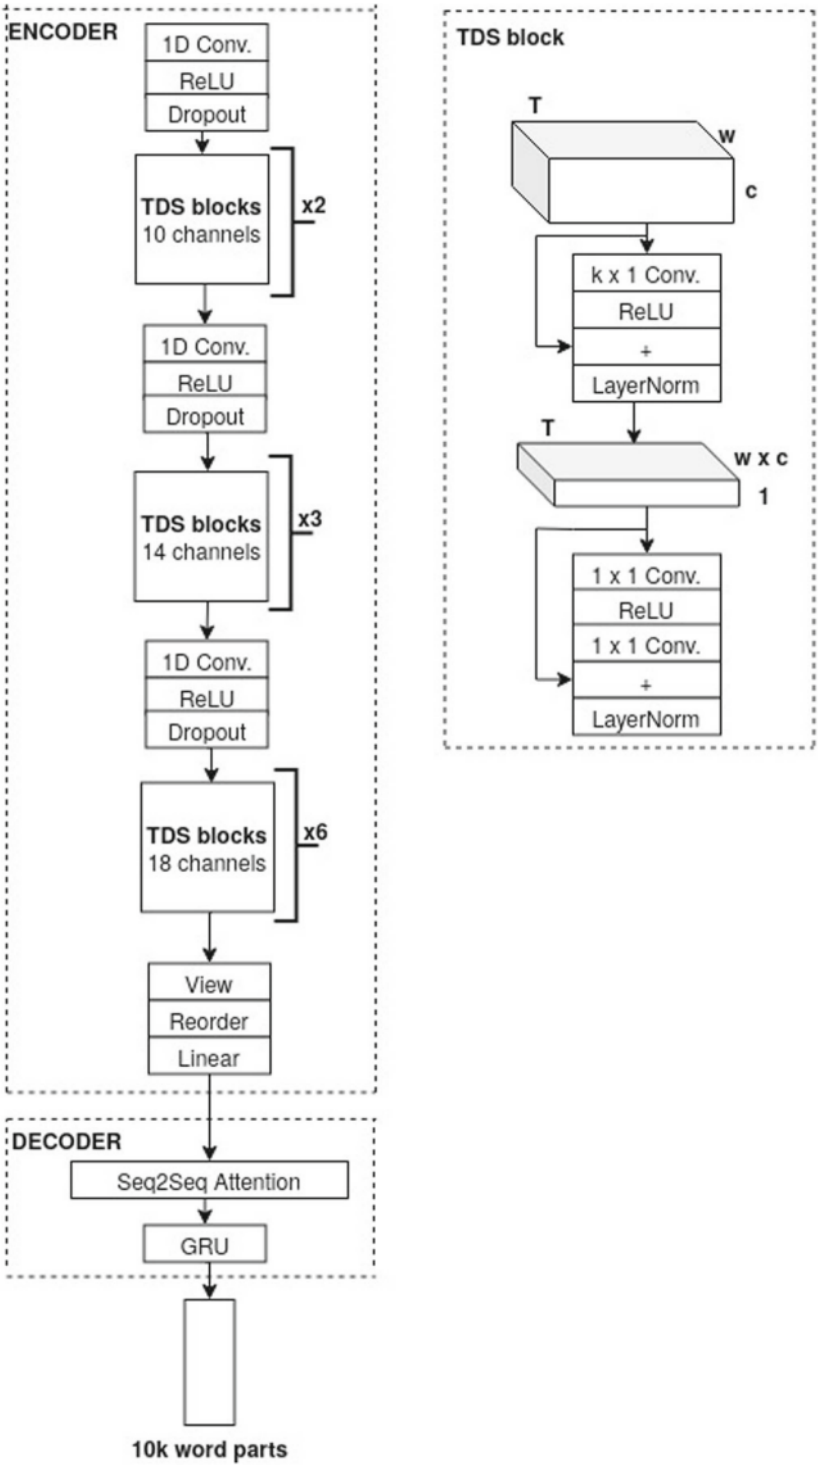
ENCODER
1D Conv.
ReLU
Dropout
TDS blocks
10 channels
x2
1D Conv.
ReLU
Dropout
TDS blocks
14 channels
x3
1D Conv.
ReLU
Dropout
TDS blocks
18 channels
x6
View
Reorder
Linear
DECODER
Seq2Seq Attention
GRU
10k word parts
TDS block
T
w
c
k x 1 Conv.
ReLU
+
LayerNorm
T
w x c
1
1 x 1 Conv.
ReLU
1 x 1 Conv.
+
LayerNorm

### 3.9 Attention-Based / Transformer

计算量过大，嵌入式可行性存疑。

## 4 Language Model 语言模型

建模文字间的依赖关系，语言模型与声学模型相对独立。

### 4.1 N-Gram

引入 $N$ 阶马尔可夫假设, 即当前文字先验概率只与前 $N$ 个文字概率相关。

使用 N-Gram 计算当前单词序列/句子 $W = W_1...W_K$ 的先验概率为:

$$P(W_1...W_K) = \Pi_{i=1}^{K} P(W_i/W_{i-1}...W_{i-N})$$

N-Gram 基于统计

### 4.2 RNN

Seq2Seq 方式建模条件概率

$$P(W_1...W_K) = \Pi_{j=1}^{K} \Pi_{i=1}^{j} P(W_i/W_{i+1}...W_{i+j})$$

神经网络输出为

$$\{P(W_2/W_1), ..., P(W_K/W_1...W_{K-1})\}$$